

AI 工牌 1.0 · 服务端周报

本周进展与下周规划 · 2026-09-04 · 用于周例会

一、本周进展

1. 端云通信协议定稿

- 完成《端云通信接口规范》v4：二进制/JSON 帧结构、消息时序、错误码表、待冻结参数清单
- 定义「边说边识别」所需的流式分片协议（音频分片 0x01 / TTS 分片 0x81 / 控制消息）

2. 测试服务器搭建

- 完成测试服务器部署：Ubuntu + Docker + PostgreSQL 16 + pgvector
- 应用 Docker 化，健康检查 UP，Flyway 迁移正常（V1-V4）

3. 微软 Azure Speech API 开通并验证

- 开通并接通微软 Azure Speech（japaneast region）
- 验证四类能力真实可用：语种判定（LID）、语音翻译（speech-to-speech）、语音转文本（ASR）、文本转语音（TTS）

4. 核心翻译链路开发

- 设备接入网关：WSS 协议、帧编解码、握手鉴权、会话管理
- 供应商抽象 + LID 软锁定 + 一步流式翻译 + Mock 降级 + 供应商路由

5. 与端侧完成第一轮端到端测试 + 时延优化 **重点**

- 第一轮端到端测试**：与端侧真机跑通翻译闭环，实测 **eou→首个 TTS 分片 时延超过 2 秒**（不达 PRD <1.5s 目标）
- 根因定位**：旧实现是「累积后处理」——说话期间云端只缓存音频分片，等 **eou** 尾包到了才一次性喂给 Azure、从零开始 ASR，等于空等了整个说话时长
- 优化方法**：改为「边说边识别」流式——音频分片到达即实时推送给 Azure recognizer，说话期间 Azure 已边听边识别；**eou** 只做「关输入流 + 等最终结果」收口，此时 ASR 已完成，只剩翻译 + 合成
- 效果**：把 ASR 耗时从「说完后」提前到「说话期间」，优化后时延待第二轮联调实测

6. 员工知识库受控 RAG (P5)

- pgvector 向量检索 → LLM 受限生成 → 非 LLM 校验（引用白名单 + 相似度，防编造）
- 四层租户隔离（检索强制带 **customer_id + store_id**）
- ⚠️ **embedding/LLM 仍是 Mock，真实 Azure OpenAI 后置**

7. 质量保障

- 68 个测试全绿（单元测试 + Testcontainers 集成测试 + 跨租户隔离验证）

二、当前联调状态

服务端已部署测试服务器，端侧可连：

项	值
公网地址	ws://120.253.215.110:8080/ws
内网地址	ws://10.0.189.32:8080/ws
演示凭据	device_id=demo-device-001 / token=demo-token-001

可测能力：fixed 翻译（已流式化）、auto 翻译（累积）、TTS 打断、员工问答（staff_qa）

三、遗留问题 / 风险（需对齐）

#	问题	影响	建议
1	auto 模式仍累积后处理（LID 未流式化）	auto 时延偏高	下周流式化 LID
2	知识库 embedding/LLM 是 Mock	员工问答检索不真实	下周接 Azure OpenAI
3	VKB 后置的 PRD 偏离记录未落实	SW-VKB 仍标 P0，与「vkb 1.0 后置」矛盾	需甲方书面确认 + 更新 PRD scope
4	待冻结参数（采样率/编码/帧长/LID 阈值等）	联调口径不一致	与 ODM EVT 验证后冻结
5	fixed 模式 language_state 显示 UNKNOWN	端侧屏幕显示不准	小修，随联调一起

四、下周规划

- 1. 第二轮端到端联调（最高优先级）：验证流式化优化后 eou→首片 TTS 时延是否达标（目标 <1.5s），并回归 TTS 打断、协议合规
- 2. 真实 Embedding/LLM 接入：P5 知识库接 Azure OpenAI（text-embedding + LLM），替换 Mock
- 3. auto 模式 LID 流式化：补齐 auto 时延短板
- 4. 落实遗留事项：VKB 偏离书面记录、待冻结参数清单

- 5. P6 后台/旁路采集：按联调进展启动