

AI 工牌 1.0 · 服务端周报

本周进展与下周规划 · 2026-09-11 · 用于周例会

一、本周进展

相对 09-04 例会，服务端完成从「单点链路验证」到「全链路实现 + 部署 + 联调准备」的收口，P1 - P6 全部完成，真实供应商全部接通，游客知识库 (VKB) 落地。

- **翻译主链路 (重点)**: 核心翻译链路 P1 - P6 全部完成并部署。翻译主链路流式化落地: 「边说边识别」, 音频分片到达即实时推送 Azure recognizer, eou 仅做「关流 + 收口」, 端到端时延达标 <1.5s。
- **LID 流式化**: auto 模式改为「一步 auto-detect」, 去掉累积后处理与 LID 置信度阈值依赖; TTS 打断、协议合规随联调回归。
- **真实供应商接入**: Azure Speech (LID / ASR / TTS)、Azure OpenAI text-embedding-3-small (embedding)、deepseek-v4-flash (LLM, 经 aibridgex) 全部接通, Mock 清零; 多供应商抽象 + 失败降级保留。
- **员工知识库 SKB 增强**: pgvector 检索 → LLM 受限生成 → 非 LLM 校验全链路; chunk 增加 answer_embedding, 校验对齐「答案 vs 答案」减少误杀; chunk 增加 keywords, 向量 miss 时关键词重叠兜底 (hybrid)。
- **游客知识库 VKB 落地**: 由「后置」转为 1.0 实现 (书面偏离已记录): 游客提问 → 译日 → 撞 VKB → 命中则「滴滴」提示服务人员 → 按 OK 确认 → 答案反向翻译成游客语言播放; 未命中 / 5s 超时回退播翻译原文。三场景脚本模拟测试通过。SKB / VKB 按 document.domain 隔离检索。
- **翻译质量门控**: AUTO 模式 short / numeric / brand / whitelist 四类分类, 低置信度不直接外放高风险译文; 品牌词表 / 白名单校准 (免税店 / 便利店 / 酒店场景)。
- **旁路采集 + 运营后台 (P6)**: 脱敏落库 translation_sample; 设备 / 知识管理 REST + RBAC 骨架。
- **知识库补全**: 补 15 条未覆盖问答 (游客 9 + 员工 6); 现 SKB 38 + VKB 21 = 59 文档 / 354 chunks。
- **云端功能模拟器**: 浏览器麦克风 → 16kHz PCM → WSS → 翻译 → TTS 播放, 角色切换替代多路拾音, 无真机也可全链路自测。
- **部署与访问升级**: 3 端口 3 页面 (58080 联调 / 58081 知识库 / 58082 模拟器), 根路径按 APP_ROLE 路由; Caddy HTTPS 已部署并放通, 反代 aicard.seasoon.net。
- **协议参数冻结 (ODM 确认)**: 16kHz / PCM16 单声道 (下行带 44 字节 WAV 头、上行裸 PCM) / 帧长 100ms / 心跳 10s / 空闲超时 20s。

二、当前部署状态

项	值
域名 / 公网	aicard.seasoon.net (120.253.215.108, HTTPS 已放通)
内网	10.0.189.32 (ssh root)
58080 → 8080	aicard-app (端侧联调, 设备连 ws://...:58080/ws)
58081 → 8081	aicard-kb (知识库测试)
58082 → 8082	aicard-sim (模拟器)
反向代理	caddy (80/443 → localhost:8082)
知识库	SKB 38 + VKB 21 = 59 文档 / 354 chunks

三、遗留问题 / 风险（需对齐）

#	问题	影响	建议
1	button_event(ok) 端侧未实现	VKB 真机联调无法进行	端侧实现 OK 键动作
2	员工方向语言漂移: visitor_language 记忆漂移 (换游客不重置 / 夹杂语言)	员工方向翻译可能偏	联调后评估防漂移
3	品牌词表 / 白名单目前静态配置	新增品牌 / 场景需改码重部署	下周做后台可配
4	pg 连接泄漏 (运维 psql 挂起)	仅影响运维, 不影响功能	运维减少 psql 频率

四、下周规划

- **端侧真机联调:** 翻译 + VKB + SKB 完整链路 (前提: 端侧 button_event(ok) 实现)。
- **后台可配接口:** 品牌词表 / 白名单后台管理 + OTA 配置下发。
- **员工方向语言漂移评估:** visitor_language 防漂移 (换游客重置、夹杂语言处理), 联调后再评估。
- **衍生产品预研:** 跨国贸易语音翻译方向, 仅纸面预研, 不写代码。